

BP神经网络

梯度下降回归

求解无约束凸函数的极小值

$$J(\theta)=\frac{1}{2m}\sum_{i=1}^m\left(h_{\theta}\left(x^{(i)}\right)-y^{(i)}\right)^2$$
$$\theta^*=\arg\min_{\theta}J(\theta)$$

线性回归回顾

$$y^{(i)}=\theta^Tx^{(i)}+\varepsilon^{(i)}$$
$$J(\theta)=\frac{1}{2}\sum_{i=1}^m\left(h_{\theta}\left(x^{(i)}\right)-y^{(i)}\right)^2$$
$$\theta=\theta-\alpha\bullet\frac{\partial J(\theta)}{\partial \theta}$$

- 1.求解无约束凸函数最小值问题
- 2.定义损失函数和梯度下降更新参数的方法

Logistic回归回顾

$$p=h_{\theta}(x)=g\left(\theta^Tx\right)=\frac{1}{1+e^{-\theta^Tx}}$$
$$g(z)=\frac{1}{1+e^{-z}}$$
$$loss=-l(\theta)=-\sum_{i=1}^m\left(y^{(i)}\ln h_{\theta}\left(x^{(i)}\right)+\left(1-y^{(i)}\right)\ln\left(1-h_{\theta}\left(x^{(i)}\right)\right)\right)$$
$$g'(z)=\left(\frac{1}{1+e^{-z}}\right)'=\frac{e^{-z}}{\left(1+e^{-z}\right)^2}$$
$$=\frac{1}{1+e^{-z}}\cdot\frac{e^{-z}}{1+e^{-z}}=\frac{1}{1+e^{-z}}\cdot\left(1-\frac{1}{1+e^{-z}}\right)$$
$$=g(z)\cdot\left(1-g(z)\right)$$
$$\theta_j=\theta_j+\alpha\sum_{i=1}^m\left(y^{(i)}-h_{\theta}\left(x^{(i)}\right)\right)x_j^{(i)}$$

将线性回归的输出通过一个逻辑函数（通常是Sigmoid函数）映射到0和1之间，得到一个概率值

p为样本属于正类的该率

神经网络之BP算法

求解w的算法，根据误差值修改每一层的权重，继续迭代

神经网络之SGD

输出层误差

$$E=\frac{1}{2}(d-O)^2=\frac{1}{2}\sum_{k=1}^{\ell}\left(d_k-O_k\right)^2$$

隐层的误差

$$E=\frac{1}{2}\sum_{k=1}^{\ell}\left(d_k-f\left(net_k\right)\right)^2=\frac{1}{2}\sum_{k=1}^{\ell}\left(d_k-f\left(\sum_{j=1}^m w_{jk}y_j\right)\right)^2$$

输入层误差

$$E=\frac{1}{2}\sum_{k=1}^{\ell}\left(d_k-f\left[\sum_{j=0}^m w_{jk}f\left(net_j\right)\right]\right)^2=\frac{1}{2}\sum_{k=1}^{\ell}\left(d_k-f\left[\sum_{j=0}^m w_{jk}f\left(\sum_{i=1}^n v_{ij}x_i\right)\right]\right)^2$$

SGD的核心思想是在每次迭代中随机选择一个样本（或一小批样本）来估计梯度，而不是使用整个数据集。这样做的优点是计算效率高，尤其是当数据集很大时。此外，SGD也能够逃离局部最小值，因为随机性引入了一定的噪声，有助于模型探索更多的参数空间

BP算法例子

FP过程

BP过程

多次迭代效果

